Bases de Données

Amélie Gheerbrant

Université Paris Diderot
UFR Informatique
Laboratoire d'Informatique Algorithmique : Fondements et Applications

amelie@liafa.univ-paris-diderot.fr

21 septembre 2014

Organisation

- 12 semaines
  Aujourd'hui : Introduction, le modèle relationnel
- Des transparents seront mis en ligne au fur et à mesure :
  `http://www.liafa.univ-paris-diderot.fr/~amelie`
  Mais attention : tout ne sera pas dedans
- Modalités de contrôle des connaissances :
  un projet (en deux phases) et un examen final

Pourquoi étudier les bases de données (BD) ?

- Avant, assez rébarbatif :
  salariés d'une entreprise, données bancaires, etc...
- Aujourd'hui les BD sont partout :
  - recherches Google
  - réseaux sociaux : Twitter, Facebook
  - musique : Spotify, Soundcloud, Discogs
  - vidéo : YouTube, DailyMotion, IMDb
  - photo : Flickr, Picasa
  - commerce : Amazon, eBay
  - voyage : Expedia, TripAdvisor, AirBnB
  - encyclopédies : Wikipedia, DBpedia
  - bases de données médicales et scientifiques
  - exploration de données (data mining)
  - intégration d'information, etc...

Une base de données, c'est quoi ?

- Une **base de données** est une collection de données structurées sur des entités (objets, individus) et des relations dans un contexte applicatif particulier
- Un système de gestion de bases de données (SGBD) est un (ensemble de) logiciel(s) qui facilite la création et l'utilisation de la base de données.
- Les données sont définies, administrées et gérées en utilisant des langages fondés sur des modèles de données.

Approche Bases de Données

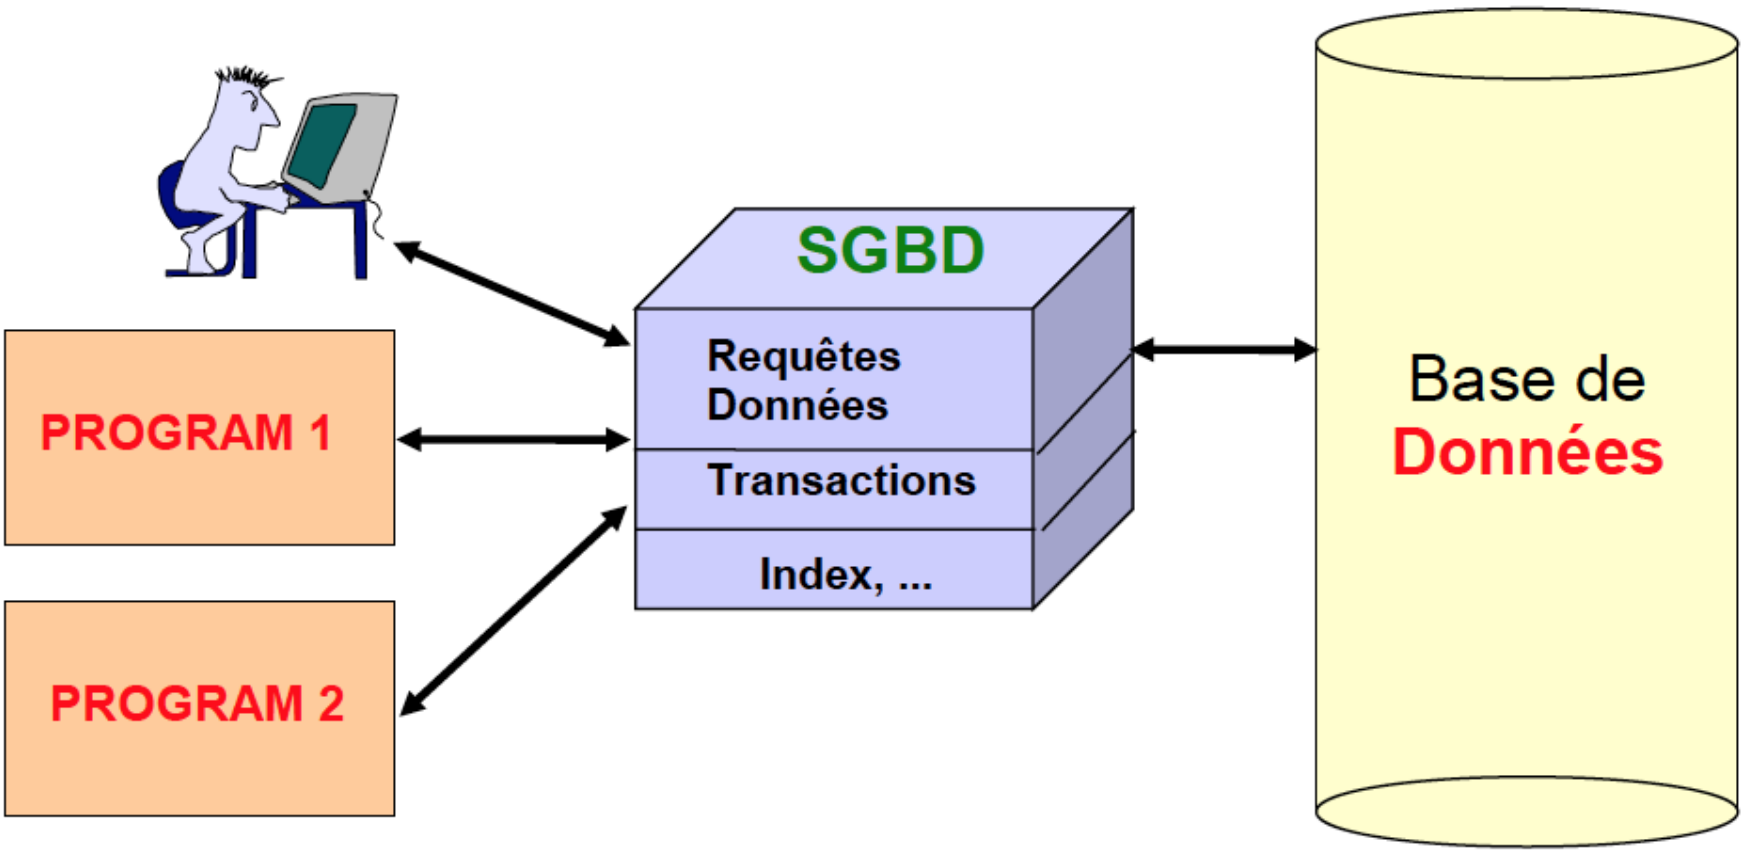

Fichiers ≠ Données

Fichier :		**Base de données :**
Faible structuration des données		Structuration des données à travers un schéma de données
Dépendance entre programmes et fichiers	⇒	Indépendance entre programmes et données
Redondance des données		Données partagées
Absence de contrôle de cohérence globale des données		Contrôle de la cohérence logique et physique (schémas, transactions)

Qu'est-ce qu'un "SGBD" ?

- Une **base de données** est une collection de données structurées sur des entités (objets, individus) et des relations dans un contexte applicatif particulier
- Un système de gestion de bases de données (SGBD) est un (ensemble de) logiciel(s) qui facilite la création et l'utilisation de la base de données.
- Les données sont définies, administrées et gérées en utilisant des langages fondés sur des modèles de données.

Systèmes de gestion de bases de données (SGBD)

- Masses de données persistantes
  - téraoctets de données survivant à l'exécution des programmes
- Stockage et accès multi-utilisateurs
  - contrôle de la concurrence
- Sécurité
  - résistance aux pannes
    (hardware, software, courant, utilisateurs malveillants)
- Facilité d'utilisation
  - opérations sur les données indépendantes de l'implémentation physique, langages de requête de haut niveau (déclaratifs)
- Efficacité
  - milliers de requêtes et mises à jour par seconde
- Fiabilité
  - 99,9999% de fiabilité (e.g., systèmes bancaires)

Approche Bases de Données : Séparation en couches indépendantes

- Séparation du problème de la gestion de données en trois « couches » :
  - Traitements (calcul, affichage, ...) ⇒ Programmes
  - Représentation logique des données ⇒ SGBD
  - Représentation physique des données ⇒ SGBD
- Couche = ensemble de sous-problèmes bien définis :
  - Indépendance traitements/représentation logique des données : vues externes cachent les détails de l'organisation logique
  - Indépendance représentation logique/représentation physique : schéma logique cache les détails du stockage physique (organisation sur disque, index, ...)

Architecture de base d'un SGBD

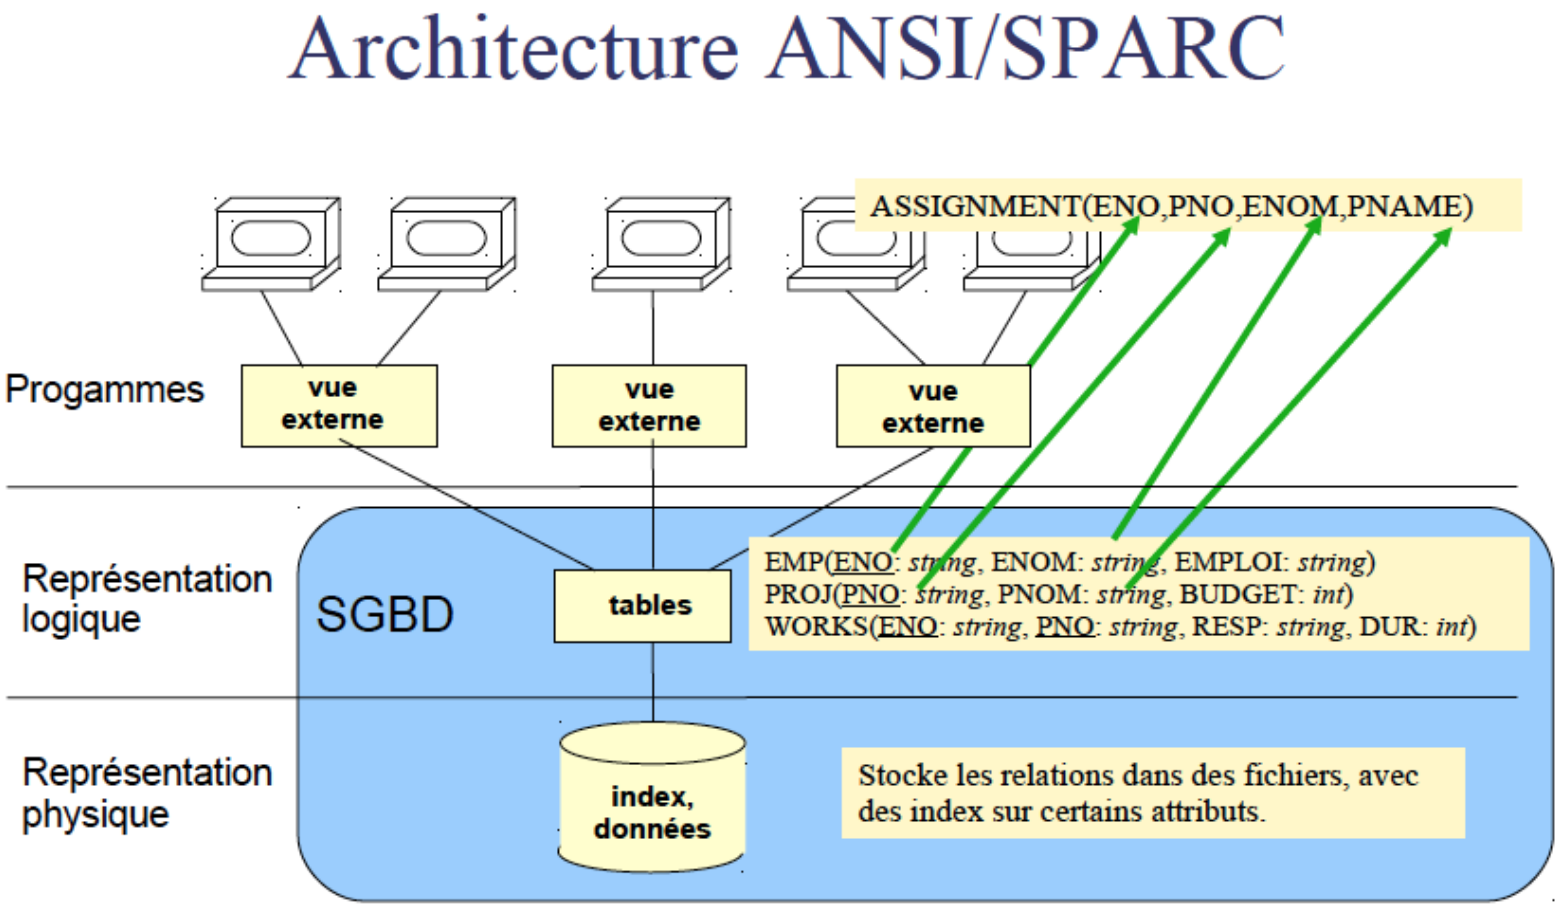

Fonctions d'un SGBD

- **Représentation et structuration de l'information** :
  - Description de la structure des données : Employé(numéro,nom,fonction)
  - Description de contraintes logiques sur les données : $0 \leq \text{age} \leq 150$
  - Vue : réorganisation (virtuelle) de données pour des besoins spécifiques
- **Gestion de l'intégrité des données** :
  - Vérification des contraintes spécifiées dans le schéma
  - Exécution transactionnelle des requêtes (mises-à-jours)
  - Gestion de la concurrence multi-utilisateur et des pannes
- **Traitement et optimisation de requêtes** :
  - La performance est un problème géré par l'administrateur du SGBD et non pas par le développeur d'application (indépendance physique)

Utilisateurs d'un SGBD

- **Utilisateur final** :
  - accède la BD par des formes d'écran, des interfaces applicatives ou, pour les plus experts, des requêtes
- **Développeur d'applications** :
  - construit (avec l'utilisateur) le schéma conceptuel
  - définit et gère le schéma logique et les vues
  - conçoit et implémente des applications qui accèdent la BD
- **Administrateur BD** :
  - gère le schéma physique et règle les performances (tuning) charge et organise la BD
  - gère la sécurité et la fiabilité

Langages et interfaces d'un SGBD

- **Langages de conception** : E/A, UML
  - Utilisation : conception haut-niveau d'applications (données et traitements)
- **Langages base de données** : SQL, XQuery, SPARQL, ...
  - langages déclaratifs : l'utilisateur spécifie quoi (et non comment)
  - puissance d'expression limitée (par rapport à un langage de programmation comme C ou Java)
  - utilisation : définition schémas, interrogation et mises-à-jour, administration
- **Langages de programmation** : PL/SQL, Java, PHP, ...
  - langages impératifs avec une interface SQL
  - langage complet (au sens d'Alan Turing)
  - utilisation : programmation d'applications complètes

Langages BD (SQL)

Langage de Définition de Données (LDD)

- pour définir les schémas externes (vues), logiques et physiques

  ex : CREATE TABLE CLIENT(NOM varchar, TEL integer) ;

Langage de Manipulation de Données (LMD)

- langage déclaratif pour interroger (langage de requêtes) et mettre à jour les données

  ex : SELECT NOM FROM CLIENT ;

  INSERT INTO CLIENT VALUES(Dupont, 0143270771) ;

- peut être autonome (par ex. SQL seul) ou intégré dans un langage de programmation, à travers une API (Application Programming Interface) comme JDBC (Java DataBase Connectivity)

Modèles de données

Modèle de données

=

langage + sémantique pour représenter et manipuler des données

- Modèle conceptuel *: conception*

  - *structuration haut-niveau (conceptuelle)* de l'information (pas d'opérations)
  - modèle ***entité-association (E/A)***, UML, Merise, …

- Modèle logique : *conception* et *développement*
  - *définition et utilisation* des données dans le SGBD
  - modèle hiérarchique, réseau, ***relationnel***, objet

```
R(A,B);
select A from R where B=2;
```

- Modèle physique : *administration*
  - *organisation physique des données et implantation des opérations*
  - modèles de stockage sur disque, indexes, algorithmes …

```
use index RI;
read record r;
```

Le modèle relationnel

- une base de données se compose de tables (relations)
- les colonnes de chaque table sont nommées par des attributs
- chaque attribut est associé à un domaine (ensemble de valeurs admissibles)
- les données dans chaque table sont constituées par l'ensemble des rangées (tuples) fournissant des valeurs pour les attributs
- pas d'ordre sur les tuples (relations = ensembles non ordonnés)
- (en général) ordre sur les valeurs des attributs dans un tuple

Exemple : la base de données "Air France"

PILOTE

PLNUM	PLNOM	PLPRENOM	VILLE	SALAIRE
1	MIRANDA	SERGE	PARIS	21000
2	LETHANH	NAHN	TOULOUSE	21000
3	TALADOIRE	GILLES	NICE	18000
4	BONFILS	ELIANE	PARIS	17000
5	LAKHAL	LOTFI	TOULOUSE	19000
6	BONFILS	GERARD	PARIS	18000
7	MARCENAC	PIERRE	NICE	17000
8	LAHIRE	PHILIPPE	LYON	15000
9	CICCHETTI	ROSINE	NICE	18000
10	CAVARERO	ANNIE	PARIS	20000

AVION

AVNUM	AVNOM	CAPACITE	LOCALISATION
1	A300	300	NICE
2	A310	300	NICE
3	B707	250	PARIS
4	A300	280	LYON
5	CONCORDE	160	NICE
6	B747	460	PARIS
7	B707	250	PARIS
8	A310	300	TOULOUSE
9	MERCURE	180	LYON
10	CONCORDE	160	PARIS

VOL

VOLNUM	*PLNUM*	*AVNUM*	VILLEDEP	VILLEARR	HEUREDEP	HEUREARR
100	1	1	NICE	TOULOUSE	11:00:00	12:30:00
101	1	8	PARIS	TOULOUSE	17:00:00	18:30:00
102	2	1	TOULOUSE	LYON	14:00:00	16:00:00
103	5	3	TOULOUSE	LYON	18:00:00	20:00:00
104	9	1	PARIS	NICE	06:45:00	08:15:00
105	10	2	LYON	NICE	11:00:00	12:00:00
106	1	4	PARIS	LYON	08:00:00	09:00:00
107	8	4	NICE	PARIS	07:15:00	08:45:00
108	1	8	NANTES	LYON	09:00:00	15:30:00
109	8	2	NICE	PARIS	12:15:00	13:45:00
110	9	2	PARIS	LYON	15:00:00	16:00:00
111	1	2	LYON	NANTES	16:30:00	20:00:00
112	4	5	NICE	LENS	11:00:00	14:00:00
113	3	5	LENS	PARIS	15:00:00	16:00:00
114	8	9	PARIS	TOULOUSE	17:00:00	18:00:00
115	7	5	PARIS	TOULOUSE	18:00:00	19:00:00

Example : la table "Avion"

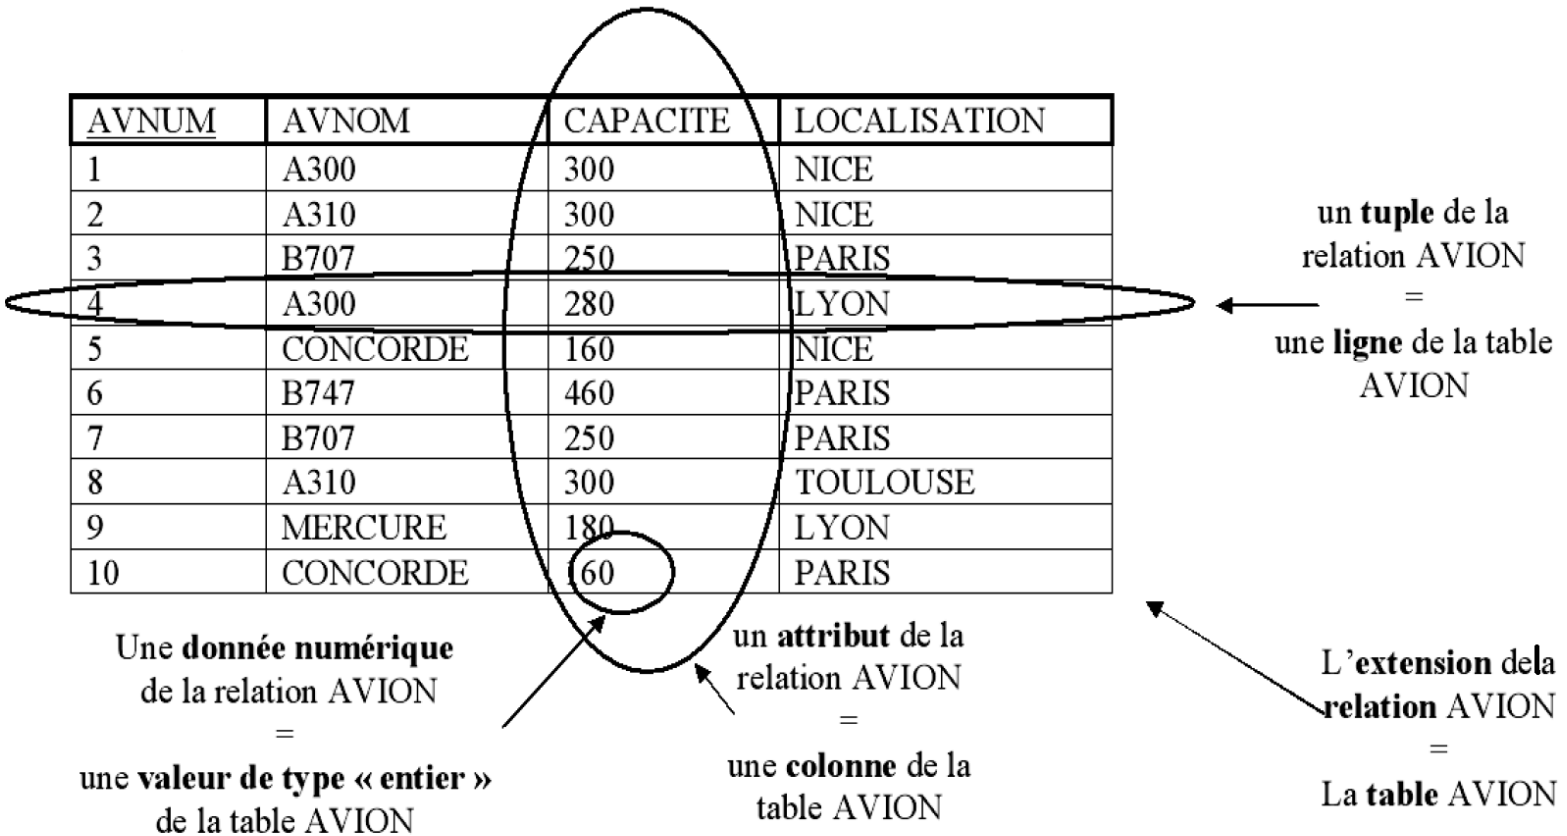

AVNUM	AVNOM	CAPACITE	LOCALISATION
1	A300	300	NICE
2	A310	300	NICE
3	B707	250	PARIS
4	A300	280	LYON
5	CONCORDE	160	NICE
6	B747	460	PARIS
7	B707	250	PARIS
8	A310	300	TOULOUSE
9	MERCURE	180	LYON
10	CONCORDE	60	PARIS

Schéma d'une relation : "Déclaration de type"

- Nom de la relation
- Ensemble des attributs
- domaine de chaque attribut
- contraintes d'intégrité

Exemple : AVION(AVNUM, AVNOM, CAPACITE, LOCALISATION)

- AVNUM : entier
- AVNOM, LOCALISATION : chaîne de caractères limitée à 30
- CAPACITÉ : entier < 1000

Types d'attribut

- Au moins un attribut par relation
- Chaque attribut d'une relation a un nom
- L'ensemble des valeurs admises pour chaque attribut est appelé le domaine de l'attribut
- Les valeurs d'attributs doivent normalement être atomiques (i.e., indivisibles)
- Jamais deux attributs identiques (nom, domaine)
- Parfois la valeur spéciale null est incluse dans le domaine
  null= absence de valeur $\neq$ 0 ou chaîne de caractères vide

Schéma et Instance

Comparable type / valeur d'une variable dans
les langages de programmation

- Schema : la structure logique de la base de données
  - Exemple : la BD contient des informations au sujet d'avions, de pilotes, de vols et de relations qu'ils entretiennent
  - $\approx$ type de la variable dans un programme
- Instance : le contenu de la base de données à un moment donné
  - $\approx$ valeur de la variable

Les tuples

- On désigne chaque valeur composant un tuple t par $t(A_i) = v_i$: la valeur de l'attribut A_i pour le tuple t
- De même, on désigne par $t(A_u, A_v, \ldots, A_w)$ les sous tuples de t contenant les valeurs des attributs $A_u, A_v, \ldots, A_w$, respectivement

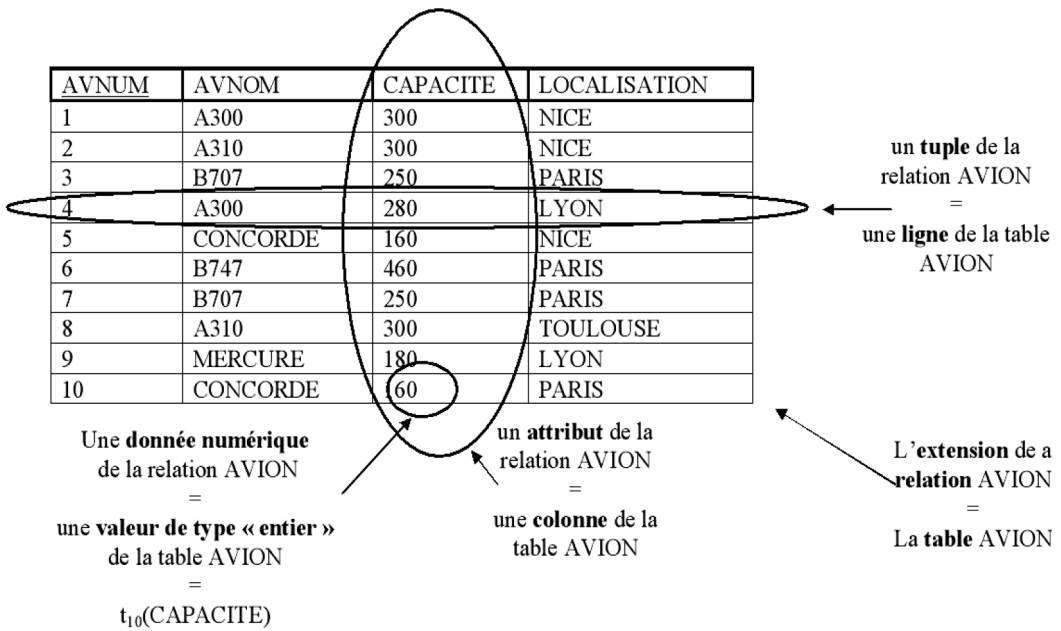

Base de données

- Une base de données se compose de plusieurs relations.
- L'information qui concerne une application est divisée en parties, chaque relation stockant une partie de l'information
  - pilote : stocke l'information sur les pilotes
  - avion : stocke l'information sur les avions
  - vol : stocke l'information sur les vols (dont le pilote et l'avion du vol)
- Stocker toute l'information dans une seule relation comme

  airfrance(plénum, plnom, plprenom, ville, salaire, avnum, avnom, capacité, localisation, volnum, villedep, villearr, heuredep, heurearr)

  est possible mais pas souhaitable :
  entraîne répétition de l'information et valeurs de données nulles

Contraintes d'intégrité

Une contrainte d'intégrité est une condition (logique)
qui doit être satisfaite par les données stockées dans la BD.

But : maintenir la cohérence / l'intégrité de la BD :

- Vérifier / valider automatiquement (en dehors de l'application) les données lors des mises à jour : insertions, modifications, effacements
- Déclencher automatiquement des mises à jour entre tables pour maintenir la cohérence globale

Exemples : clefs primaires, clefs étrangères

Clefs primaires

- La clé primaire d'une relation R est l'attribut ou l'ensemble d'attributs (avec le moins d'attributs possible) qui identifie de manière unique chaque tuple de la relation.
- Exemple :
  PLNUM est la clé primaire de PILOTE car (on suppose que) chaque pilote possède un numéro unique.
- La clé primaire est soulignée.
- Il n'y a qu'une seule clé primaire par relation.

Clefs primaires

La valeur des attributs clefs primaires ne peut jamais être nulle dans aucun tuple de R.
⇒ Clefs primaires utilisées pour identifier les tuples individuels

$t(A) \neq null$ pour tout tuple t d'une instance valide de R, où A est une clef primaire

Note : on peut aussi requérir que des attributs n'appartenant pas à la clef primaire soient non nuls.

Clefs primaires

Exemple de relation avec une clef primaire composée de plusieurs attributs :

NOM	PRENOM	AGE	ADRESSE	GROUPE	...
Dupont	Jean	21	45 rue des sources	INFO1	...
Dupont	Jeanne	21	45 rue des sources	INFO1	...
...	...	...	...	...	...

- Pour différencier les étudiants, prendre en même temps : nom, prénom, âge et adresse.
- Clef primaire : (NOM,PRENOM,AGE,ADRESSE)

('Dupont','Jean',7,'45 rue des sources')

$\neq$

('Dupont','Jeanne',7,'45 rue des sources')

Dépendances d'inclusion

- Dépendance d'inclusion "E inclus dans F"
  - entre un sous-ensemble d'attributs E d'une relation R et un autre F d'une relation S
  - notée $R.E \subseteq S.F$
- Si et Seulement Si
  l'ensemble des valeurs de chaque tuple de R pour les attributs de E est inclus dans l'ensemble des valeurs de chaque tuple de S pour les attributs de F.
- Abréviation : DI

Dépendances d'inclusion

On a :
VOL.AVNUM⊆AVION.AVNUM
car toute valeur de
VOL.AVNUM est dans
AVION.AVNUM.

AVION

AVNUM	AVNOM	CAPACITE	LOCALISATION
1	A300	300	NICE
2	A310	300	NICE
3	B707	250	PARIS
4	A300	280	LYON
5	CONCORDE	160	NICE
6	B747	460	PARIS
7	B707	250	PARIS
8	A310	300	TOULOUSE
9	MERCURE	180	LYON
10	CONCORDE	160	PARIS

VOL

VOLNUM	*PLNUM*	*AVNUM*	VILLEDEP	VILLEARR	HEUREDEP	HEUREARR
100	1	1	NICE	TOULOUSE	11:00:00	12:30:00
101	1	8	PARIS	TOULOUSE	17:00:00	18:30:00
102	2	1	TOULOUSE	LYON	14:00:00	16:00:00
103	5	3	TOULOUSE	LYON	18:00:00	20:00:00
104	9	1	PARIS	NICE	06:45:00	08:15:00
105	10	2	LYON	NICE	11:00:00	12:00:00
106	1	4	PARIS	LYON	08:00:00	09:00:00
107	8	4	NICE	PARIS	07:15:00	08:45:00
108	1	8	NANTES	LYON	09:00:00	15:30:00
109	8	2	NICE	PARIS	12:15:00	13:45:00
110	9	2	PARIS	LYON	15:00:00	16:00:00
111	1	2	LYON	NANTES	16:30:00	20:00:00
112	4	5	NICE	LENS	11:00:00	14:00:00
113	3	5	LENS	PARIS	15:00:00	16:00:00
114	8	9	PARIS	TOULOUSE	17:00:00	18:00:00
115	7	5	PARIS	TOULOUSE	18:00:00	19:00:00

Dépendances d'inclusion

- On peut avoir une dépendance d'inclusion entre attributs d'une même table : R.E $\subseteq$ R.F
- On peut avoir une dépendance d'inclusion entre deux ensembles d'attributs :
  - R.(Attr1,Attr3)$\subseteq$S.(Attr5,Attr8)
  - les couples de valeurs (Attr1,Attr3) de R doivent se retrouver dans les couples de valeurs (Attr5,Attr8) de S
  - Exemple : VOL.(AVNUM,VILLEDEP)$\not\subseteq$AVION.(AVNUM,LOCALISATION)

Dépendances d'inclusion

On a :
VOL.(AVNUM,VILLEDEP)
$\not\subseteq$
AVION.(AVNUM,LOCALISATION)
car

?

AVION

AVNUM	AVNOM	CAPACITE	LOCALISATION
1	A300	300	NICE
2	A310	300	NICE
3	B707	250	PARIS
4	A300	280	LYON
5	CONCORDE	160	NICE
6	B747	460	PARIS
7	B707	250	PARIS
8	A310	300	TOULOUSE
9	MERCURE	180	LYON
10	CONCORDE	160	PARIS

VOL

VOLNUM	PLNUM	AVNUM	VILLEDEP	VILLEARR	HEUREDEP	HEUREARR
100	1	1	NICE	TOULOUSE	11:00:00	12:30:00
101	1	8	PARIS	TOULOUSE	17:00:00	18:30:00
102	2	1	TOULOUSE	[illegible]N	14:00:00	16:00:00
103	5	3	TOULOUSE	LYON	18:00:00	20:00:00
104	9	1	PARIS	NICE	06:45:00	08:15:00
105	10	2	LYON	NICE	11:00:00	12:00:00
106	1	4	PARIS	LYON	08:00:00	09:00:00
107	8	4	NICE	PARIS	07:15:00	08:45:00
108	1	8	NANTES	LYON	09:00:00	15:30:00
109	8	2	NICE	PARIS	12:15:00	13:45:00
110	9	2	PARIS	LYON	15:00:00	16:00:00
111	1	2	LYON	NANTES	16:30:00	20:00:00
112	4	5	NICE	LENS	11:00:00	14:00:00
113	3	5	LENS	PARIS	15:00:00	16:00:00
114	8	9	PARIS	TOULOUSE	17:00:00	18:00:00
115	7	5	PARIS	TOULOUSE	18:00:00	19:00:00

Clefs étrangères

- Un attribut ou un ensemble d'attributs d'une relation R est clef étrangère de R ssi :
  - cet attribut (ou ensemble d'attributs) est partie gauche d'une DI de R (à gauche du symbole $\subseteq$)
  - si la DI a en partie droite la clef primaire d'une relation S (S peut être égale à R)
- On écrit les clés étrangères en italiques.

Clefs étrangères

Exemple de clef étrangère :
AVNUM est clef étrangère de VOL car

- on a la DI :
  VOL.AVNUM $\subseteq$ AVION.AVNUM
  (clef étrangère en partie gauche & clef primaire en partie droite)
- et AVNUM est clé primaire de AVION

Contraintes d'intégrité

- Contraintes dite d'intégrité référentielle (relatives aux dépendances d'inclusion)
  si R.E$\subseteq$S.F, alors :
  - quand on insère dans R une nouvelle valeur pour l'attribut E,
  - on doit s'assurer que cette valeur existe dans l'attribut F de S
- Exemple : VOL.AVNUM $\subseteq$ AVION.AVNUM
  - pour ajouter un vol dans la relation VOL,
  - l'avion correspondant doit figurer dans la relation AVION.

Autres types de contraintes

Il existe d'autres types de contraintes plus fines :

- "tous projets cumulés, un même employé ne peut travailler plus de 56h par semaine"
- "le salaire d'un employé ne peut jamais être baissé"

$\Rightarrow$ langages de spécification de contraintes
$\Rightarrow$ triggers, ASSERTIONS

Opérations de mise à jour sur les relations

- INSERT : insertion de tuples
- DELETE : suppression de tuples
- UPDATE : mises à jour de tuples

Les contraintes d'intégrité ne doivent pas être violées par les opérations de mises à jour !

En cas de violation d'intégrité, plusieurs actions sont possibles :

- annuler l'opération en cause (option REJECT)
- réaliser l'opération mais informer l'utilisateur de la violation
- déclencher ("trigger") des mises à jour additionnelles de façon à ce que la violation soit corrigée
- exécuter une routine spécifique de correction d'erreur

Objectifs de ce cours

Apprendre :

1. **La conception de bases de données**
   - Point de départ : description informelle d'une application
   - Abstraction et optimisation du cahier des charges (modélisation)
   - Création d'entités comprises par le système (extraction des relations de la base de données)
   - Optimisation des relations (normalisation)

2. **L'utilisation d'un SGBD**
   - Ecrire des requêtes dans un langage (SQL) compris par le SGBD (Oracle, PostgreSQL, MySQL, DB2, etc)